

HACKATHON IDU

Qualité de la Donnée Pédagogique

Audit des données de maquetage et de déploiement de l'emploi du temps IDU

Formation IDU – Ingénierie des Données et Usages (3e, 4e, 5e année)	Format 12 heures en 3x4h
Équipes 3 à 5 étudiants – composition libre	Livrable Rapport d'audit de qualité des données + démo ou restitution orale

1. Contexte et enjeux

La filière IDU (Informatique des Données et Usages) de Polytech Annecy-Chambéry s'appuie sur un écosystème de données structuré pour planifier et déployer ses enseignements. Cet écosystème repose sur plusieurs sources hétérogènes :

Source	Format	Contenu clé	Risques qualité identifiés
MAQUETTE_IDU	JSON (BDD)	37 modules, heures CM/TD/TP, ECTS	Volumes horaires vs réel ADE, codes modules non normalisés
ADECal IDU 3/4/5	JSON (ADE export)	618+ événements/an, salles, enseignants, groupes	Titres incohérents, séances sans module code, chevauchements
Responsables modules	JSON (BDD)	Correspondance module ↔ enseignant responsable	Modules sans responsable, doublons potentiels
Dépendances séquences	JSON (BDD)	Ordres pédagogiques CM→TD→TP par module	Violations de séquençement dans l'ADE
Résumé Moodle	HTML	Données de suivi pédagogique Moodle	Cohérence avec maquette officielle

Ces sources forment ensemble la « chaîne de données pédagogiques » : de la conception de la maquette jusqu'à l'effectivité de l'emploi du temps déployé dans ADE. Des incohérences entre ces niveaux génèrent des impacts concrets : séances mal référencées sur Moodle, violations de prérequis pédagogiques, difficultés de pilotage pour les responsables de formation...

2. Objectif du hackathon

L'objectif central est de produire un audit de qualité complet et argumenté de ces données pédagogiques, en mobilisant les dimensions suivantes du référentiel qualité de la donnée :

Dimension	Définition appliquée au contexte IDU	Exemple de question d'audit
Complétude	Tous les modules de la maquette sont-ils présents dans ADE ?	Des modules ont-ils 0 séance planifiée malgré des heures prévues ?
Exactitude	Les volumes horaires ADE correspondent-ils aux heures maquette (CM/TD/TP) ?	INFO634 : 9h CM prévus – combien de CM dans ADE ?
Cohérence	Les codes modules sont-ils uniformes entre toutes les sources ?	INFO631_IDU vs INFO631_INGE_TDG : même module ?
Conformité	Les séquences pédagogiques (CM avant TD) sont-elles respectées ?	Un TD a-t-il été planifié avant le CM correspondant ?
Unicité	Les créneaux ne se chevauchent-ils pas pour un même groupe ou enseignant ?	Kavé Salamatian en double salle simultanément ?
Traçabilité	Peut-on reconstituer la chaîne Maquette → Moodle → ADE pour chaque module ?	La description ADE renvoie-t-elle au bon code Moodle ?

Cette liste n'est pas exhaustive, elle a pour vocation à vous permettre de vous lancer, son enrichissement sera un plus pour votre rapport d'audit.

3. Les deux approches

Les équipes peuvent choisir l'une des deux approches suivantes, ou proposer une approche hybride combinant les deux. L'approche choisie doit être justifiée dans le rapport d'audit final.

APPROCHE A — Développement d'outils d'audit (DevOps & Qualité logicielle)

Les équipes développent un pipeline logiciel d'audit de qualité des données, en respectant les bonnes pratiques DevOps et de qualité logicielle vues en IDU.

A.1 Périmètre technique attendu

- ▶ **Ingestion** : Parseurs et ingestion des sources hétérogènes
 - JSON (MAQUETTE, ADE, Responsables, Dépendances) → modèle de données unifié
 - HTML (Résumé Moodle) → extraction structurée
 - Gestion des encodages, dates avec timezone (UTC+0 dans ADE), valeurs nulles
- ▶ **Règles métier** : Moteur de règles de qualité
 - Règles déclaratives (ex : chaque module maquette doit avoir ≥ 1 séance ADE)
 - Règles de séquençement à partir de `dependance_sequence_IDU.json`
 - Détection de chevauchements temporels par enseignant/groupe/salle
- ▶ **Restitution** : Dashboard de résultats et rapport automatisé
 - Métriques par dimension qualité (taux de complétude, nb anomalies, etc.)
 - Visualisations (heatmap modules/semaines, graphe de dépendances, timeline)
 - Export rapport JSON/HTML/PDF

A.2 Contraintes DevOps & qualité logicielle

- ▶ Versioning Git avec branches, commits atomiques et messages conventionnels (Conventional Commits)
- ▶ Tests unitaires sur les parseurs et le moteur de règles (couverture $\geq 70\%$)

- ▶ CI/CD minimal : pipeline de tests automatiques (GitHub Actions ou équivalent)
- ▶ Documentation technique : README, schéma d'architecture, exemples d'exécution
- ▶ Containerisation optionnelle (Docker) valorisée

A.3 Stack technique suggérée (non imposée)

Composant	Options
Langage principal	Python (pandas, networkx, plotly, great-expectations) JavaScript/TypeScript
Stockage intermédiaire	SQLite, DuckDB, ou DataFrames en mémoire
Visualisation	Plotly, D3.js, Observable, Streamlit, Dash
Tests	pytest, unittest Jest, Vitest
CI/CD	GitHub Actions, GitLab CI
Rapport	Jupyter Notebook exporté, HTML généré, PDF via WeasyPrint

APPROCHE B — Audit analytique via outils tiers (BI & Data Quality)

Les équipes utilisent des outils no-code ou low-code de qualité de la donnée et de Business Intelligence pour analyser, profiler et visualiser les données IDU, sans développer de pipeline from scratch.

B.1 Périmètre analytique attendu

- ▶ **Profilage** : Profiling des données sources
 - Distribution des types de séances (CM/TD/TP) par module et par année
 - Détection des valeurs manquantes, aberrantes ou mal formatées
 - Cartographie des modules sans responsable ou avec responsable multiple
- ▶ **Croisement** : Analyse de cohérence inter-sources
 - JOIN maquette × ADE : quels modules ont un écart > 10% sur les heures ?
 - Vérification des contraintes de séquençement via graphe ou tableau croisé
 - Analyse des enseignants les plus chargés (charge horaire ADE vs maquette)
- ▶ **Dashboard** : Tableau de bord interactif
 - Vue synthétique par année (IDU3, IDU4, IDU5) avec indicateurs qualité
 - Navigation par module, enseignant, ou semaine calendaire
 - Export des anomalies détectées sous forme de liste priorisée

B.2 Outils suggérés (non imposés)

- ▶ Profiling & qualité : Great Expectations, Soda Core, OpenMetadata, Atlan
- ▶ BI & visualisation : Power BI, Tableau Public, Metabase, Superset, Grafana
- ▶ Transformation : dbt (avec DuckDB), Pandas Profiling / YData Profiling
- ▶ Graphe de dépendances : Gephi, Neo4j Bloom, ou visualisation D3 basique
- ▶ Intégration données : OpenRefine pour nettoyage interactif des sources

B.3 Livrables attendus (approche B)

- ▶ Fichier de configuration de l'outil de qualité (règles déclarées, seuils définis)
- ▶ Dashboard exportable (PDF ou lien public si outil cloud)
- ▶ Rapport d'audit narratif commentant les résultats obtenus
- ▶ Inventaire des anomalies avec criticité (bloquant / majeur / mineur)

4. Approche hybride (Mix A+B)

Une approche hybride est encouragée : elle consiste à développer des composants logiciels ciblés (approche A) pour les traitements que les outils tiers ne couvrent pas bien (ex : vérification des graphes de dépendances, parsing des titres ADE), tout en utilisant des outils BI pour la restitution finale.

Exemple de découpage hybride recommandé

- ÉTAPE 1 (Dev) : Script Python de normalisation des titres ADE → extraction du code module canonique
- ÉTAPE 2 (Dev) : Calcul des écarts heures maquette vs ADE → export CSV enrichi
- ÉTAPE 3 (Analytique) : Import du CSV dans Power BI / Metabase pour dashboard
- ÉTAPE 4 (Dev) : Moteur de règles de séquençement → liste d'anomalies JSON
- ÉTAPE 5 (Analytique) : Visualisation des anomalies dans Grafana ou Superset
- LIVRABLE : Rapport consolidé combinant métriques outillées + analyse narrative

5. Description des données fournies

Les fichiers ci-dessous sont mis à disposition de chaque équipe. Leur exploration et leur compréhension constituent la première étape de travail.

5.1 MAQUETTE_IDU.json — Maquette officielle de la formation

Contient 37 modules répartis sur les années IDU 3 à 5 (codes IDU et PACY). Chaque module porte : code unique, intitulé, ECTS, volumes horaires CM / TD / TP en heures decimales.

- ▶ Périmètre : 3 années de formation, ~15 modules par année
- ▶ Champs critiques : code_module (clé de jointure), cm / td / tp (référence horaire)
- ▶ Point d'attention : certains modules ont 0h CM ou 0h TP (ex : projets), ce qui est normal mais doit être validé

5.2 ADECal_IDU3/4/5.json — Emploi du temps ADE exporté

Export calendrier brut depuis ADE pour chaque promo (IDU-3, IDU-4, IDU-5). Chaque événement porte : Title (non normalisé), Location (salle + capacité), Starts / Ends (datetime UTC), Description (multilignes avec groupes et enseignant).

- ▶ Volume : ~600+ événements par promo et par année académique
- ▶ Problème connu : Title utilise des codes non standards (ex : INFO631_INGE_TDG au lieu de INFO631_IDU)
- ▶ À noter : certains événements sont hors-IDU (rentrée, BDE, LANG, EASI) → filtrage nécessaire
- ▶ Timezone : toutes les heures sont en UTC+0, l'heure locale France est UTC+1 ou UTC+2 en été

5.3 Responsables_modules_IDU.json — Table de responsabilité

Associe chaque code_module à un enseignant responsable (nom + prénom). 35 entrées couvrant les modules IDU et PACY. Enseignants identifiés : VERNIER, SALAMATIAN, MONNET, CIMPAN, ALLOUI, ATTO, MIAN, BENOIT, VALET.

5.4 dependance_sequence_IDU.json — Graphe pédagogique de séquencement

Définit les contraintes d'ordre pédagogique entre séances : chaque entrée exprime qu'une séance (module, type, numéro) doit précéder une autre. Types : CM, TD, TP, Exam, PROJ.

- ▶ Structure : DAG (graphe orienté acyclique) de dépendances intra-module
- ▶ Usage : vérifier que dans ADE, la séance précédente a bien eu lieu avant la suivante
- ▶ Complexité : certains modules ont des graphes de dépendances non linéaires (ex : ISOC631_IDU alterne CM/TD)

5.5 Re_sume_Moodle_IDU.html — Résumé de déploiement Moodle

Document HTML exporté depuis Moodle, contenant les informations de déploiement des ressources pédagogiques par module. Permet de croiser la dimension plateforme numérique avec la maquette officielle.

6. Livrables et critères d'évaluation

6.1 Livrables obligatoires (toutes approches)

- ▶ 1. Rapport d'audit de qualité (10 à 20 pages)
 - Synthèse exécutive : score global de qualité par dimension, nombre d'anomalies par criticité
 - Analyse détaillée : méthodologie, règles appliquées, résultats par source
 - Recommandations priorisées : actions correctives suggérées
- ▶ 2. Démo ou restitution orale (15 min + 5 min questions)
 - Présentation du pipeline ou du dashboard
 - Illustration de 3 anomalies concrètes détectées avec leur impact pédagogique
- ▶ 3. Dépôt Git ou archive de tous les artefacts produits

6.2 Livrables spécifiques par approche

APPROCHE A — Dev	APPROCHE B — Analytique
✓ Code source versionné (Git) ✓ Suite de tests avec rapport de couverture ✓ Pipeline exécutable avec README ✓ Schéma d'architecture du système ✓ Rapport de qualité généré automatiquement	✓ Configuration outil qualité (règles déclarées) ✓ Dashboard exporté (PDF ou lien) ✓ Notebook ou script de transformation ✓ Inventaire des anomalies (Excel ou JSON) ✓ Rapport narratif commenté

6.3 Grille d'évaluation

Critère	Points	Ce qui est évalué
---------	--------	-------------------

Qualité de l'audit produit	30 pts	Pertinence des règles, profondeur de l'analyse, exhaustivité
Anomalies identifiées et priorisées	20 pts	Nb et pertinence des anomalies, classification (bloquant/majeur/mineur)
Qualité technique (approche A) ou outil (approche B)	20 pts	Code propre + tests (A) Outil bien configuré, règles pertinentes (B)
Présentation et communication	15 pts	Clarté, pédagogie, capacité à contextualiser les résultats
Recommandations actionnables	15 pts	Pertinence, faisabilité, lien avec les anomalies détectées

7. Pistes de travail et questions-guides

Les questions suivantes sont des points de départ pour orienter l'investigation. Les équipes ne sont pas tenues de toutes les traiter, mais chaque question abordée doit être documentée avec sa méthodologie et ses résultats.

7.1 Cohérence maquette ↔ ADE (Complétude & Exactitude)

- ▶ Quels modules de la maquette IDU n'ont aucune séance identifiable dans ADE ?
- ▶ Pour chaque module, l'écart entre les heures maquette (CM/TD/TP) et les heures ADE dépasse-t-il un seuil acceptable (ex : $\pm 15\%$) ?
- ▶ Certains modules ont-ils des séances de type non prévu par la maquette (ex : TP pour un module sans TP) ?

7.2 Normalisation des identifiants (Cohérence & Unicité)

- ▶ Peut-on établir une table de correspondance fiable entre les titres ADE (ex : INFO631_INGE_TDG) et les codes maquette (ex : INFO631_IDU) ?
- ▶ Existe-t-il des doublons ou des titres ambigus pointant vers plusieurs modules possibles ?
- ▶ Les descriptions ADE contiennent-elles toujours les informations de groupe et d'enseignant ?

7.3 Respect des dépendances pédagogiques (Conformité)

- ▶ Pour les modules couverts par `dependance_sequence_IDU.json`, les séances sont-elles planifiées dans le bon ordre chronologique dans ADE ?
- ▶ Existe-t-il des cas où un TD a été planifié avant le CM dont il dépend ? (Anomalie bloquante)
- ▶ Y a-t-il des séances dans ADE qui ne correspondent à aucune dépendance définie (séances orphelines) ?

7.4 Conflits et chevauchements (Unicité)

- ▶ Un même enseignant est-il planifié dans deux salles différentes au même créneau ?
- ▶ Un groupe IDU se voit-il attribuer deux séances simultanées ?
- ▶ La capacité des salles utilisées est-elle compatible avec le nombre de groupes concernés ?

7.5 Analyse de charge des enseignants (Traçabilité & Exactitude)

- ▶ Quelle est la charge horaire ADE réelle de chaque enseignant responsable de module par rapport aux heures maquette dont il est responsable ?
- ▶ Certains enseignants interviennent-ils sur des modules dont ils ne sont pas responsables selon la table Responsables_modules_IDU ?

8. Organisation pratique

Phase	Contenu
Phase 0 (1h)	Kick-off : présentation du sujet, questions de clarification, constitution et déclaration des équipes
Phase 1 (3-4h)	Exploration des données : profiling initial, identification des anomalies évidentes, choix de l'approche
Phase 2 (12-16h)	Développement / configuration : implémentation des règles, pipeline ou dashboard, tests
Phase 3 (4-6h)	Analyse et rédaction : interprétation des résultats, rédaction du rapport d'audit, recommandations
Phase 4 (2h)	Préparation de la restitution : slides, démo, argumentation
Restitution finale	15 min de présentation + 5 min de questions par équipe devant le jury

9. Points bonus et défis supplémentaires

Défis optionnels pour les équipes avancées

- ★ DÉFI 1 — Automatisation continue : mettre en place un pipeline CI qui re-génère l'audit à chaque mise à jour des données (GitHub Actions + rapport HTML publié en artifact)
- ★ DÉFI 2 — Scoring de qualité composite : définir un Data Quality Score global pour l'IDU (pondération des dimensions, indice 0-100) justifié par une méthodologie publiée (DAMA, ISO 8000...)
- ★ DÉFI 3 — Détection d'anomalies par ML : utiliser un modèle de détection d'outliers (Isolation Forest, LOF) sur les volumes horaires pour identifier des séances atypiques
- ★ DÉFI 4 — Interface web interactive : déployer un mini-dashboard web (Streamlit, Dash) permettant de filtrer les anomalies par module, année, ou enseignant en temps réel
- ★ DÉFI 5 — Proposition de correction : pour les anomalies de séquençement, générer automatiquement une proposition de réordonnancement de créneaux ADE compatible avec les contraintes pédagogiques

10. Références et ressources

Standards qualité de la donnée

- ▶ DAMA International — Data Management Body of Knowledge (DMBOK), 2e édition

- ▶ ISO/IEC 25012 : Qualité des données (modèle de qualité, 15 caractéristiques)
- ▶ Great Expectations Documentation : <https://docs.greatexpectations.io>
- ▶ Soda Core : <https://www.soda.io/resources/introduction-to-data-quality>

Cours IDU mobilisés

- ▶ INFO832_IDU — Qualité et tests logiciel (normes, CI/CD, couverture de tests)
- ▶ DATA732_IDU — Analyse et visualisation de données
- ▶ INFO834_IDU — Bases de données distribuées (modélisation, jointures)
- ▶ INFO733_IDU — Réseaux et Systèmes répartis (architectures de pipeline)
- ▶ PROJ631_IDU / PROJ832_IDU — Projets algorithmiques et flux de données

Annexe — Catalogue des modules IDU par année

Extrait de MAQUETTE_IDU.json — Les codes marqués * désignent des modules communs avec la filière PACY.

Code	Intitulé	ECTS	CM(h)	TD(h)	TP(h)	Resp.
▶ Année IDU-3						
INFO501_PACY*	Algorithmes et Structures de données	1.5	12	10.5	16	MIAN
INFO502_PACY*	Initiation aux BD	2.0	6	4.5	12	VERNIER
INFO631_IDU	Logique et Programmation	2.75	10.5	10.5	20	VERNIER
INFO632_IDU	Systèmes d'exploitation et Virtualisation	3.0	10.5	13.5	16	MONNET
INFO633_IDU	Programmation BD et site web	2.5	0	13.5	10	VALET
INFO634_IDU	Conception et Programmation OO	2.75	9	21	8	CIMPAN
ISOC531_IDU	Sociétés numériques	3.0	13.5	22.5	4	SALAMATIAN
ISOC631_IDU	Plateformes collaboratives	3.0	13.5	15	12	SALAMATIAN
MATH531_IDU	Graphes et Langages	3.0	12	12	16	VERNIER
PROJ531_IDU	Gestion de projets	3.0	6	6	28	ALLOUI
PROJ631_IDU	Projet Algorithmique	2.75	0	42	0	VERNIER
PROJ632_IDU	APP Projet Data Science	2.5	0	30	0	VERNIER
▶ Année IDU-4						
DATA731_IDU	Modélisation Stochastique	3.0	12	0	24	ATTO
DATA732_IDU	Analyse et visualisation de données	3.0	12	23.5	0	CIMPAN
INFO731_IDU	Sécurité et Cryptographie	3.0	13.5	22.5	4	SALAMATIAN
INFO732_IDU	Comportement et Modélisation Dynamique	2.5	7.5	6	24	CIMPAN
INFO733_IDU	Réseaux et Systèmes répartis	2.5	18	16	4	SALAMATIAN
INFO734_IDU	Développement Full Stack	3.0	12	24	0	MIAN
ISOC731_IDU	Économie et gouvernance de la donnée	3.0	15	21	4	SALAMATIAN
PROJ731_IDU	APP Analyse et visualisation	2.0	0	20	0	CIMPAN
DATA831_IDU	Big Data	1.0	7.5	0	12	MONNET
DATA832_IDU	Machine Learning	2.5	9	9	12	BENOIT
DATA931_IDU	Machine Learning (avancé)	3.0	12	12	16	BENOIT
INFO831_IDU	Informatique décisionnelle	2.5	9	9	12	ATTO
INFO832_IDU	Qualité et tests logiciel	2.5	12	12	16	VERNIER
INFO833_IDU	Systèmes distribués à large échelle	2.5	12	13.5	15	MONNET
INFO834_IDU	Bases de données distribuées	2.5	6	6	28	ALLOUI
▶ Année IDU-5						
INFO931_IDU	Optimisation et aide à la décision	3.0	12	12	16	MONNET
INFO932_IDU	Cloud Computing	3.0	7.5	7.5	24	MONNET
ISOC831_IDU	Dimension métiers	1.5	30	0	0	VERNIER
ISOC931_IDU	Innovation et Recherche	3.0	6	12	20	BENOIT
PROJ831_IDU	APP Projet IDU	1.5	0	20	0	VERNIER
PROJ832_IDU	Flux de Données et Accès Concurrents	1.5	4	16	0	MONNET
PROJ931_IDU	Projet Usages	4.0	0	0	40	MONNET
PROJ932_IDU	Projet Data Science	4.0	0	0	40	MONNET
PROJ901_PACY*	Projet R&D	7.0	0	0	40	—